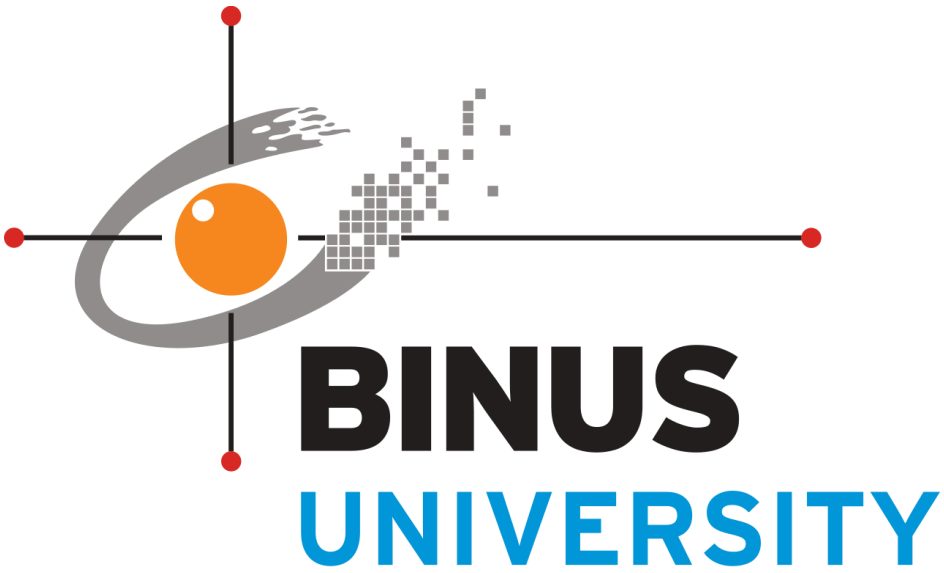
Laporan Tugas Deep Learning



Oleh :

Nama : Juan Jonathan Suparmo
NIM : 2802477023
Kelas : LB01

Bagian A - Analisis Konseptual

1. Efek regularisasi Batch Normalization (Slide 6–7)

Pada saat training, Batch Normalization menormalkan aktivasi memakai mean dan varians mini-batch (μ_B, σ^2_B), bukan statistik populasi. Karena komposisi batch berubah tiap iterasi, nilai ternormalisasi sebuah sampel mengandung noise stokastik, sampel yang sama diperlakukan sedikit berbeda pada tiap epoch. Noise ini bekerja serupa injeksi derau pada Dropout, mengurangi koadaptasi neuron dan menghambat memorisasi (Ioffe & Szegedy, 2015). Efeknya lebih kuat pada batch kecil karena estimasi μ_B dan σ^2_B lebih bervariasi.

Asumsi "Dropout tidak diperlukan" tidak lagi berlaku ketika: (i) batch besar sehingga noise statistik kecil dan regularisasi melemah, (ii) batch sangat kecil sehingga statistik terlalu noisy dan pelatihan tidak stabil (Wu & He, 2018, menyarankan GroupNorm), (iii) model sangat besar, misalnya head fully-connected, yang tetap overfit; (iv) terjadi ketidaksesuaian statistik train vs inference, misalnya BN dibiarkan mode train saat fine-tuning pada data kecil atau distribution shift.

2. Degradasi jaringan dalam dan formulasi residual (Slide 9-11)

Degradation problem bukan overfitting: training error plain CNN yang lebih dalam justru lebih tinggi (He et al., 2016). Secara teori lapisan tambahan dapat menjadi identity mapping, tetapi dalam praktik optimizer sulit mengaproksimasi identitas melalui tumpukan lapisan nonlinear berbobot acak, sehingga optimasi menjadi lebih sulit. Blok residual memformulasikan $y = x + F(x)$; untuk menjadi identitas, lapisan cukup mendorong $F(x) \to 0$, yang jauh lebih mudah. Pada backpropagation, $\partial L/\partial x = \partial L/\partial y \cdot (I + \partial F/\partial x)$. Suku identitas I menyediakan jalur gradien langsung tanpa perkalian Jacobian berantai. Pada Sesi 02, vanishing gradient muncul karena perkalian banyak faktor berkelipatan kecil (<1) sepanjang lapisan, skip connection memutus rantai perkalian tersebut sehingga lapisan awal tetap menerima sinyal gradien yang bermakna.

3. Feature Extraction vs. Fine-Tuning (Slide 14–16)

Trainable parameters: feature extraction hanya melatih head (ResNet-18: 5.130 parameter), fine-tuning melatih sebagian/seluruh backbone (layer 4 saja sudah jutaan parameter). Volume data: feature extraction cukup dengan data sangat sedikit karena kapasitas yang dilatih kecil; fine-tuning butuh lebih banyak data agar tidak overfit. Komputasi dan memori: feature extraction lebih murah (tidak ada gradien dan state optimizer untuk backbone; fitur bahkan dapat di-cache), fine-tuning menyimpan aktivasi untuk backward dan state AdamW untuk

lapisan yang dibuka. Risiko destructive gradient updates, nol pada feature extraction, tetapi nyata pada fine-tuning bila learning rate terlalu besar atau head yang masih acak. Kriteria, pilih feature extraction jika data sangat sedikit, domain mirip ImageNet, atau komputasi terbatas, sedangkan pilih fine-tuning (bertahap, lr kecil) bila data cukup banyak dan/atau domain berbeda sehingga fitur tingkat tinggi perlu disesuaikan.

4. Kaidah penerapan Data Augmentation (Slide 20-21)

Augmentasi hanya diaktifkan pada train set karena tujuannya memperluas variasi data latih sebagai regularisasi. Validation/test set harus merepresentasikan distribusi data nyata secara deterministik: jika dihaluskan atau didistorsi secara acak, metrik menjadi noisy, tidak dapat dibandingkan antar eksperimen, dan tidak mencerminkan performa deployment. Augmentasi pada val/test juga membuat early stopping dan pemilihan model bergantung pada keacakan. Contoh transformasi yang tidak layak untuk klasifikasi ras hewan, hue shift ekstrem pada ColorJitter. Warna bulu merupakan fitur diskriminatif ras (misalnya Samoyed putih, Abyssinian kemerahan), pergeseran hue besar mengubah ciri yang menentukan label sehingga invariansi semantik label tidak terpenuhi dan model dilatih pada pasangan citra–label yang menyesatkan. Vertical flip juga tidak realistis karena pose hewan peliharaan hampir selalu tegak.

5. Mitigasi Catastrophic Forgetting (Slide 27–29)

Catastrophic forgetting terjadi ketika update gradien pada data baru yang kecil menggeser bobot pretrained jauh dari basin optimum asalnya, sehingga fitur umum (tepi, tekstur, bentuk) tertimpa oleh fitur spesifik data baru (Kirkpatrick et al., 2017). Risiko terbesar muncul saat learning rate besar atau head masih acak sehingga gradien awal besar dan tidak informatif merambat ke backbone. Strategi 1, differential learning rate: lapisan awal/pretrained memakai lr kecil karena sudah menyimpan fitur umum yang hanya perlu disesuaikan sedikit, sedangkan head baru memakai lr besar agar cepat konvergen. Strategi 2, gradual unfreezing (Howard & Ruder, 2018), head dilatih lebih dulu hingga gradiennya bermakna, lalu lapisan dibuka bertahap dari atas ke bawah, sehingga gradien noisy dari head acak tidak merusak backbone. Linear warmup melengkapi keduanya dengan menstabilkan estimasi momen Adam pada langkah awal.

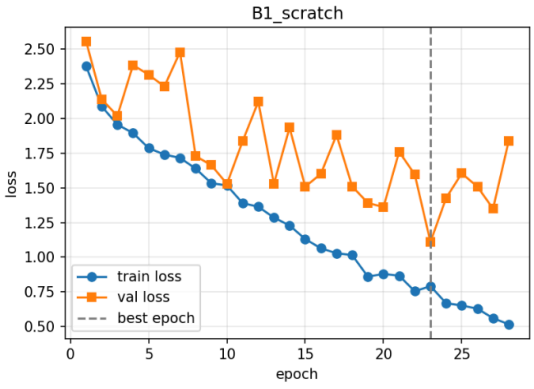
Bagian B - Eksperimen Praktek

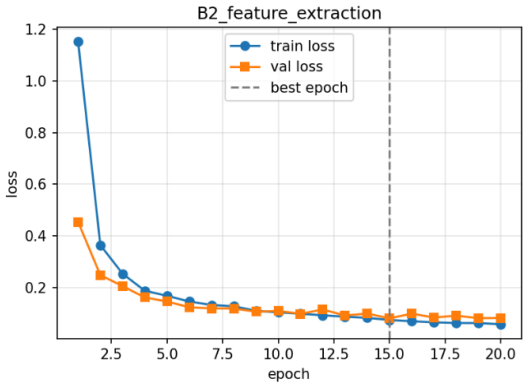
Dataset : Oxford-IIIT Pet
Link : torchvision.datasets.OxfordIIITPet

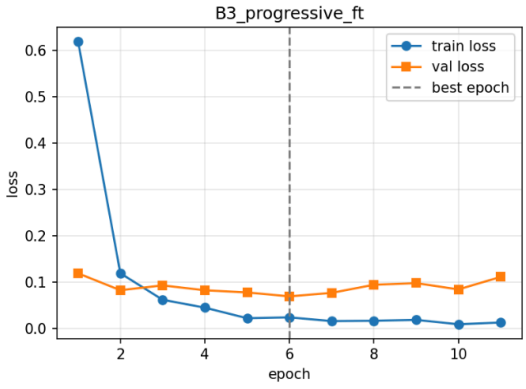
Bagian C - Laporan dan Analisis

C1. Tabel Konsolidasi dan Visualisasi Pembelajaran

Kondisi	Trainable params	LR	Best epoch (dijalankan)	Waktu (s)	Val acc	Test Macro F1	Gap train-val
B1 Scratch	11.181.642	1e-3	23 (28)	213,6	0,6522	0,6548	0,0730
B2 Feature Extraction	5.130	head 1e-3	15 (20)	147,8	0,9799	0,9668	0,0129
B3 Progressive FT	8.398.858	layer4 1e-4 / fc 1e-3	6 (11)	80,2	0,9900	0,9699	0,0065
B4 B3 tanpa aug	8.398.858	sama	4 (9)	45,4	0,9766	0,9732	0,0234
B4 B3 dengan aug	8.398.858	sama	6 (11)	80,5	0,9900	0,9699	0,0065
B5 EfficientNet-B0	1.142.202 (total 4,0 jt)	sama	8 (13)	95,0	0,9933	0,9801	0,0060
B5 MobileNetV3-Small	1.245.738 (total 1,5 jt)	sama	5 (10)	71,9	0,9331	0,9669	0,0604







C2. Pembahasan Analisis Komparatif

1. Disparitas B1 dengan transfer learning (B2 dan B3)

Pelatihan dari nol (B1) hanya mencapai Macro F1 test 0,6548, jauh di bawah B2 (0,9668) dan B3 (0,9699). Penyebab utamanya adalah data: ResNet-18 memiliki 11,18 juta parameter, sedangkan data latih hanya sekitar 1.400 citra, sehingga B1 harus mempelajari seluruh hierarki fitur visual dari awal, sementara B2 dan B3 memakai fitur umum hasil pre training ImageNet (Slide 14, 16). Pada epoch pertama, validation accuracy B1 hanya 0,174 dibanding 0,933 (B2) dan 0,963 (B3), dan validation loss B1 berfluktuasi tajam (1,109–2,121 setelah epoch 8). Gap train-val B1 hanya 0,0730 dengan akurasi train 0,7251, sehingga B1 mengalami underfitting, bukan overfitting. Skip connection (Slide 10–12) memungkinkan jaringan dalam dioptimasi, tetapi tidak menggantikan kebutuhan data. Train loss B1 masih menurun saat early stopping berhenti, sehingga 0,6548 dibaca sebagai batas bawah pada anggaran pelatihan ini.

2. Trade-off feature extraction vs fine-tuning

B2 dan B3 menghasilkan performa test yang hampir sama (Macro F1 0,9668 vs 0,9699; selisih satu citra dari 300, sehingga tidak dapat dibedakan dari noise pada single seed). B3 konvergen lebih cepat (best epoch 6 vs 15) dan val accuracy lebih tinggi (0,9900 vs 0,9799), tetapi melatih 8.398.858 parameter dibanding 5.130 pada B2, dan validation loss-nya naik setelah epoch 6 (0,0694 menjadi 0,1114) saat train loss terus turun, tanda awal overfitting. B2 lebih stabil dan bebas risiko catastrophic forgetting (Slide 28) karena backbone beku, namun konvergensinya lebih lambat. Pada data terbatas, B2 sudah memadai (Slide 29); B3 memberi keuntungan kecil dengan risiko overfitting lebih tinggi.

3. Peran augmentasi (B4)

Augmentasi pada B3 menurunkan gap train-val dari 0,0234 menjadi 0,0065. Tanpa augmentasi, akurasi train mencapai 1,0000 sejak epoch 3 sementara validation loss mendatar (0,078–0,082), tanda model menghafal data latih; dengan augmentasi, validation accuracy naik dari 0,9766 ke 0,9900 dan validation loss turun dari 0,0778 ke 0,0694 (Slide 20). Namun pada test set, Macro F1 tanpa augmentasi justru sedikit lebih tinggi (0,9732 vs 0,9699; selisih satu citra dari 300). Jadi augmentasi mengecilkan celah generalisasi, tetapi manfaat akurasinya tidak dapat dipastikan, kemungkinan karena model pretrained sudah menggeneralisasi dengan baik. Kesimpulan ini berdasarkan satu seed dan augmentasi yang ringan.

4. Arsitektur pembanding (B5) (bonus)

Strategi B3 diterapkan pada EfficientNet-B0 dan MobileNetV3-Small. EfficientNet-B0 mencapai Macro F1 0,9801 (val acc 0,9933) dengan total 4.020.358 parameter, sekitar sepertiga ResNet-18 (11.181.642 parameter; F1 0,9699), sejalan dengan rancangan compound scaling yang efisien (Slide 24). Selisihnya hanya sekitar tiga citra dari 300, sehingga belum cukup untuk menyatakan EfficientNet lebih unggul. MobileNetV3-Small paling ringan (1.528.106 parameter) dengan Macro F1 0,9669, setara B2, tetapi gap train-val 0,0604 dan val accuracy 0,9331 menunjukkan generalisasi yang kurang stabil; selisih besar antara val accuracy dan test F1 juga menandakan satu pembagian validasi saja tidak cukup andal. Waktu per epoch ketiga arsitektur serupa (sekitar 7,2–7,3 detik) karena didominasi pemuatan data, dan cakupan lapisan yang dibuka berbeda tiap arsitektur, sehingga perbandingan ini bersifat indikatif.

C3. Failure Analysis (Analisis Kasus Misklasifikasi)

No	File	Aktual	Prediksi (conf.)	Hipotesis penyebab
1	pug_74	Pug	Boxer (0,965)	Anjing berwarna fawn dengan moncong gelap, duduk tegak di kursi sehingga proporsi tubuh tampak lebih mirip Boxer. Ambiguitas visual antar ras; model sangat yakin meski salah.
2	Bengal_143	Bengal	Abyssinian (0,658)	Foto close-up yang agak blur dan kontras rendah. Pola khas Bengal tidak terlihat jelas, warna cokelat keabuan lebih mirip Abyssinian.
3	Siamese_150	Siamese	Abyssinian (0,641)	Kucing hanya sebagian terlihat di tepi kanan (terpotong), sementara mesin jahit dan kain bermotif mendominasi frame. Oklusi dan bias latar belakang.
4	Abyssinian_150	Abyssinian	Bengal (0,521)	Cahaya matahari kuat membuat warna oranye sangat jenuh, kucing berbaring dengan kepala miring dan mata

No	File	Aktual	Prediksi (conf.)	Hipotesis penyebab
				setengah tertutup. Pencahayaan dan sudut ekstrem.
5	Bengal_34	Bengal	Abyssinian (0,490)	Kepala menengadah (profil), warna kemerahan seragam, ada tangan manusia dan rumput di latar sebagai distraktor.
6	shiba_inu_156	Shiba Inu	Beagle (0,380)	Pola bulu tricolor (putih, cokelat, hitam) tampak atipikal untuk Shiba Inu dan lebih mirip Beagle. Confidence rendah, model ragu.

Dari 300 citra test, EfficientNet-B0 salah memprediksi 6 citra (2%). Seluruh kesalahan terjadi di dalam spesies yang sama (kucing tertukar dengan kucing, anjing dengan anjing) dan tidak ada kesalahan kucing–anjing, sehingga kesulitan model terletak pada proses pembedaan antar-ras yang mirip, bukan antar-spesies. Tiga dari enam kesalahan melibatkan pasangan Abyssinian–Bengal, dua ras kucing dengan warna bulu dasar cokelat-oranye yang mirip. Kesalahan paling berisiko adalah Pug yang diprediksi Boxer dengan confidence 0,965, sedangkan lima kesalahan lain memiliki confidence 0,38 - 0,66, sehingga ambang confidence berpotensi dipakai untuk menandai prediksi yang perlu ditinjau manusia.

C4. Rekomendasi Rekayasa dan Batasan Eksperimen

Klaim	Kekuatan bukti
Transfer learning jauh lebih baik dari pelatihan dari nol (F1 0,97 vs 0,65)	Kuat (selisih ratusan citra, bukan 1–3 citra)
Augmentasi mengecilkan gap train-val (0,0234 menjadi 0,0065)	Sedang (terlihat di gap dan val loss, tidak di test)
B3 konvergen lebih cepat dari B2 (epoch 6 vs 15)	Sedang (konsisten di kurva, tetapi satu seed)

Klaim	Kekuatan bukti
B2 vs B3 vs EfficientNet mana yang terbaik	Lemah (selisih 1–4 citra dari 300, di dalam noise)

Rekomendasi:

Untuk skenario data terbatas (sekitar 1.400 citra latih, 10 kelas) dengan domain yang mirip ImageNet, kami merekomendasikan transfer learning, dan tidak melatih dari nol, karena B1 hanya mencapai Macro F1 0,6548 dibanding sekitar 0,97 pada B2 dan B3. Urutan kerja yang disarankan:

(1) mulai dari feature extraction (B2) karena paling murah (5.130 parameter), stabil, tanpa risiko catastrophic forgetting, dan sudah mencapai F1 0,9668, sejalan dengan saran Slide 29

(2) bila target akurasi belum tercapai, lanjut ke fine-tuning bertahap (B3) dengan differential learning rate dan early stopping, yang pada eksperimen kami konvergen lebih cepat (epoch 6 vs 15) tetapi mulai overfit setelahnya

(3) pakai augmentasi sebagai praktik standar karena memperkecil gap train-val tanpa biaya tambahan, meskipun manfaat akurasinya pada test set tidak terbukti di sini

(4) bila ukuran model menjadi kendala, EfficientNet-B0 (4,0 juta parameter vs 11,2 juta pada ResNet-18) mencapai F1 0,9801 dan layak diuji, namun selisihnya dari ResNet-18 hanya sekitar tiga citra dari 300 sehingga belum cukup untuk menyatakan lebih unggul. Prediksi dengan confidence rendah (lima dari enam kesalahan memiliki confidence 0,38–0,66) dapat ditandai untuk ditinjau manusia, tetapi kesalahan dengan confidence tinggi (Pug sebagai Boxer, 0,965) tidak akan tertangkap oleh cara ini.

Kondisi berlaku (operational constraints). Rekomendasi ini berlaku untuk: domain citra alami yang mirip ImageNet (ras kucing dan anjing termasuk kategori yang dikenal ImageNet), ratusan citra per kelas, satu GPU kelas T4, dan tersedia set validasi terpisah untuk early stopping. Untuk domain yang sangat berbeda (misalnya citra medis atau satelit) kemungkinan dibutuhkan fine-tuning lebih dalam, tetapi hal ini tidak diuji dalam studi ini.

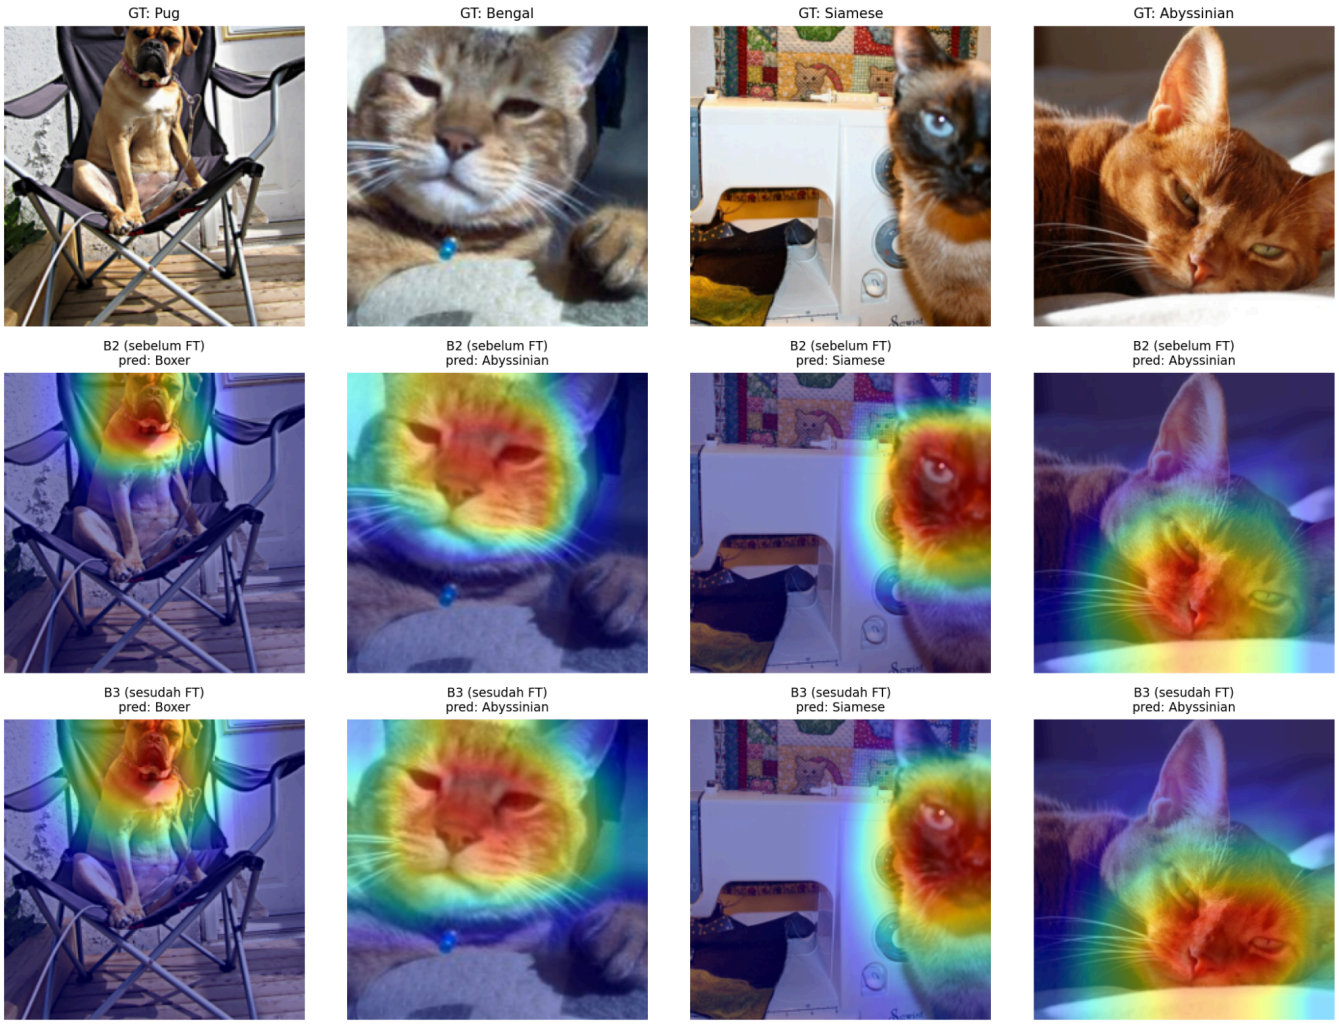
Limitasi studi:

1. Single seed (42): tidak ada estimasi variansi antar-run, sehingga perbedaan kecil antar kondisi tidak dapat dinyatakan signifikan secara statistik.

2. Test set kecil (300 citra): satu citra setara 0,33 poin persentase, sedangkan selisih antara B2, B3, B4, dan B5 hanya 1–4 citra.
3. Cakupan sempit: hanya 10 kelas dari satu dataset (Oxford-IIIT Pet) pada domain yang dekat dengan ImageNet, sehingga hasil transfer learning mungkin lebih optimistis dibanding domain lain.
4. Hyperparameter tidak di-tuning: learning rate, weight decay, kekuatan augmentasi, dan batch size tetap sesuai protokol. B1 kemungkinan belum konvergen penuh (train loss masih menurun saat early stopping berhenti), sehingga selisihnya terhadap B2 dan B3 bisa terlalu besar.
5. Efisiensi komputasi tidak terukur sepenuhnya: waktu per epoch hampir sama pada semua kondisi (sekitar 7 detik) karena didominasi pemuatan data; memori dan latensi inferensi tidak diukur, dan bagian backbone yang dibuka berbeda pada tiap arsitektur di B5.
6. Pemilihan model memakai validation set kecil (sekitar 300 citra): pada MobileNetV3-Small, validation accuracy (0,9331) jauh lebih rendah daripada test Macro F1 (0,9669), menunjukkan satu pembagian data belum cukup andal.
7. Skenario B4 hanya diuji pada B3 dan augmentasi yang dipakai tergolong ringan; hasil B4 dengan augmentasi identik dengan B3 sehingga bukan replikasi independen.

C5. Eksplorasi Tambahan (Nilai Tambah / Opsional)

Grad-CAM pada layer4 dihitung untuk kelas ground truth pada empat citra test, dua di antaranya salah diprediksi oleh ResNet-18 (Pug dan Bengal) dan dua benar (Siamese dan Abyssinian), membandingkan B2 (sebelum fine-tuning; backbone beku dengan head terlatih) dan B3 (sesudah fine-tuning layer4). Pada kedua model, aktivasi tertinggi berada pada tubuh hewan, terutama wajah, bukan pada latar belakang; pada citra Siamese, fokus tetap pada wajah kucing meskipun latar didominasi mesin jahit dan kain bermotif. Pergeseran akibat fine-tuning terlihat halus: pada citra Pug dan Bengal area aktivasi B3 tampak lebih luas, sedangkan pada Siamese dan Abyssinian kedua model hampir identik. Pola ini sejalan dengan selisih performa B2 dan B3 yang kecil (Macro F1 0,9668 vs 0,9699) dan dengan fine-tuning yang hanya melibatkan layer4 pada learning rate rendah (1e-4), yang menyesuaikan fitur tingkat tinggi tanpa mengubahnya secara drastis (Slide 28–29). Pada dua kasus salah, kedua model tetap salah dengan fokus pada area yang wajar, sehingga kesalahan diduga lebih berkaitan dengan kemiripan antar-ras daripada fokus yang keliru. Visualisasi ini bersifat kualitatif dan terbatas pada empat citra.



Tools : Google Colab

Penggunaan AI :

- Claude Sonnet 5.5 (membuat codingan dan debugging)
- Google Gemini 3.1 Pro (merangkai kata-kata, mencari referensi, merapihkan laporan, memperbaiki ejaan kata)